



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 1

Análisis Exploratorio e Inferencial (práctica)

Informe individual o grupal · 0 % (formativa)

Título del proyecto: Análisis del Riesgo Crediticio
Integrantes: «nombres completos (3-4 integrantes)»
Dataset: Give Me Some Credit (riesgo crediticio)
Docente: «nombre del docente»
Fecha: «dd/mm/aaaa»
Repositorio GitHub: <https://github.com/usuario/repositorio>

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información

Modalidad: Grupal **Ponderación:** 0 % (formativa)

Entregable: Informe en formato PDF, subido a Canvas

Resultado de aprendizaje (RA1): aplicar conceptos fundamentales de probabilidad e inferencia estadística en la resolución de problemas de decisión bajo incertidumbre.

Indicadores: ID1.2, ID1.3, ID1.4.

Índice

1	Introducción	2
2	Aplicación de estadística descriptiva	2
3	Estimación puntual e intervalos de confianza	4
4	Aplicación de una prueba de hipótesis	4
5	Documentación de procedimientos y resultados	6
6	Interpretación preliminar de resultados	6
7	Presentación formal del informe	7
8	Participación en el foro	7
8.1	Aporte inicial	7
8.2	Comentarios a otros grupos	7

1. Introducción

Presenten brevemente el conjunto de datos definido por el equipo en la fase anterior del proyecto y el propósito de este informe de avance.

Para esta fase se trabajó con el dataset *Give Me Some Credit*, un conjunto del ámbito **financiero** orientado al *scoring* de riesgo de crédito. Reúne información de **150.000 prestatarios**, cada uno descrito por once variables, e indica si la persona registró un **atraso grave de 90 o más días** dentro de un horizonte de dos años. Esa es la variable objetivo, **SeriousDlqin2yrs**.

La decisión de fondo es la de siempre en la banca, es decir, antes de aprobar un crédito conviene estimar qué tan probable es que el solicitante no pague. Este informe de avance es una primera caracterización estadística del conjunto. Incluye estadística descriptiva, estimación por intervalos de confianza y pruebas de hipótesis, y deja sentadas las bases del modelamiento posterior. Los cálculos usan la semilla 42 y están documentados en el cuaderno adjunto.

2. Aplicación de estadística descriptiva

(15 pts, ID1.2) Caractericen las variables del conjunto de datos mediante medidas de tendencia central, dispersión y representaciones gráficas adecuadas a cada tipo de variable.

El conjunto reúne una variable objetivo binaria y diez predictores, todos numéricos. Tres son de naturaleza continua (utilización de crédito, ratio de deuda e ingreso), la edad se comporta de forma cuasi-continua y el resto son conteos. La Tabla 1 resume la tendencia central y la dispersión de las variables numéricas.

Tabla 1: Medidas descriptivas de las variables numéricas (150.000 observaciones).

Variable	Media	Mediana	Desv. est.	Mínimo	Máximo
Utilización de crédito	6,05	0,15	249,76	0	50.708
Edad	52,30	52,00	14,77	0	109
Atrasos 30-59 días	0,42	0,00	4,19	0	98
Ratio de deuda	353,01	0,37	2.037,82	0	329.664
Ingreso mensual	6.670,22	5.400	14.384,67	0	3.008.750
Líneas/préstamos abiertos	8,45	8,00	5,15	0	58
Atrasos 90+ días	0,27	0,00	4,17	0	98
Préstamos inmobiliarios	1,02	1,00	1,13	0	54
Atrasos 60-89 días	0,24	0,00	4,16	0	98
N.º de dependientes	0,76	0,00	1,12	0	20

La Figura 1(a) deja ver de entrada una característica interesante e incómoda a la vez, la variable objetivo está desbalanceada, con apenas un **6,7%** de clientes morosos. Se suman **datos faltantes** en dos variables, el ingreso mensual (19,8%) y el número de dependientes (2,6%), que aparecen en la Figura 1(b). Y hay indicios de valores extremos y de errores de captura. En el ingreso y el ratio de deuda la media queda muy por encima de la mediana, señal de una distribución asimétrica. También se puede ver un registro con **age=0**, los valores 98 en las variables de atrasos (códigos especiales) y 609 filas duplicadas.




Figura 1: (a) Distribución de la variable objetivo (desbalance). (b) Porcentaje de datos faltantes por variable.

La Figura 2 nos muestra la forma de tres variables representativas. La edad se distribuye de manera casi simétrica. El ingreso se concentra en valores bajos y arrastra una cola larga hacia la derecha (lo graficamos recortado al percentil 99 para que se logre ver bien), y el número de líneas y préstamos también se acumula en cifras pequeñas.




Figura 2: Distribución de tres variables cuantitativas representativas, con su media o mediana.

La matriz de correlaciones (Figura 3) nos muestra un detalle que conviene tener presente, y es que las **tres variables de atrasos están casi perfectamente correlacionadas entre sí** (r entre 0,98 y 0,99). Miden, en la práctica, el mismo comportamiento. El resto de las correlaciones son débiles a moderadas.




Figura 3: Matriz de correlaciones entre las variables numéricas.

3. Estimación puntual e intervalos de confianza

(15 pts, ID1.3) Utilicen métodos de estimación puntual e intervalos de confianza para determinar parámetros poblacionales relevantes del conjunto de datos, interpretando los resultados.

Se estimaron tres parámetros poblacionales con un nivel de confianza del 95%, usando la aproximación normal que justifica el Teorema Central del Límite para las medias y la proporción. La Tabla 2 resume los valores.

Tabla 2: Estimación puntual e intervalos de confianza al 95%.

Parámetro	Estimación	IC 95%
Edad media (años)	52,30	[52,22; 52,37]
Ingreso mensual medio	6.670,22	[6.588,9; 6.751,5]
Proporción de morosidad	0,06684	[0,06558; 0,06810]

Interpretación. Los intervalos son estrechos, consecuencia del gran tamaño muestral. Con 150.000 observaciones la incertidumbre sobre las medias es mínima, por lo tanto, podemos afirmar con un 95% de confianza que la edad media poblacional está entre 52,22 y 52,37 años, y que la proporción de morosos cae entre 6,56% y 6,81%. La media del ingreso (6.670) supera con holgura a su mediana (5.400), lo que confirma la asimetría que ya mostraba el histograma. Aun así, con 150.000 observaciones el Teorema Central del Límite garantiza que la media muestral se distribuya de forma aproximadamente normal, de modo que su intervalo sigue siendo válido pese a la cola larga.

4. Aplicación de una prueba de hipótesis

(15 pts, ID1.4) Apliquen al menos una prueba de hipótesis básica, seleccionando el procedimiento adecuado según el tipo de variable y el nivel de significancia definido.

¿La edad media difiere entre clientes morosos y no morosos? Se comparan las medias de una variable cuantitativa entre dos grupos con varianzas y tamaños distintos, así que el procedimiento adecuado es la **prueba t de Welch**, que no asume varianzas iguales. El nivel de significancia es $\alpha = 0,05$:

$$H_0 : \mu_{\text{moroso}} = \mu_{\text{no moroso}} \quad \text{vs.} \quad H_1 : \mu_{\text{moroso}} \neq \mu_{\text{no moroso}}.$$

Las medias muestrales son 45,93 años en los morosos y 52,75 en los no morosos. El estadístico da $t = -50,58$ con un valor $p < 0,0001$, de modo que se **rechaza** H_0 . El tamaño del efecto (d de Cohen = $-0,47$) es moderado: la edad separa a los grupos, aunque no de forma tajante.

Una prueba χ^2 de independencia entre el tramo etario y la morosidad confirma la asociación ($\chi^2 = 1.884,9$; gl = 4; $p < 0,0001$; V de Cramér = 0,11). La Figura 4 ordena el patrón: la tasa de morosidad baja de forma sostenida con la edad, desde 11,7% en menores de 30 años hasta 2,0% en mayores de 75.




Figura 4: Tasa de morosidad grave por tramo etario, con la media global de referencia.

Si la edad pesa de manera moderada, cabe preguntarse qué variable discrimina mejor. El historial de pagos. Comparamos la morosidad entre quienes registran al menos un atraso de 30 a 59 días y quienes no registran ninguno (sin contar los códigos especiales), con una **prueba z de dos proporciones**. Entre los primeros la morosidad llega al 20,4%; entre los segundos, al 4,0%. La diferencia ($z = 93,3$; $p < 0,0001$) equivale a un **riesgo relativo de 5,1 veces**. La Figura 5 muestra cómo ese riesgo escala con el número de atrasos acumulados.




Figura 5: Tasa de morosidad grave según el número de atrasos previos de 30-59 días, con la media global de referencia.

5. Documentación de procedimientos y resultados

(15 pts) Documenten de forma clara, ordenada y completa los procedimientos estadísticos aplicados y los resultados obtenidos, de manera que el análisis sea trazable.

Todo el análisis se hizo en **Python**, con **pandas**, **numpy**, **scipy** y **matplotlib**, y es reproducible fijando la semilla 42. El cuaderno adjunto (`Formativa1_GiveMeSomeCredit_Codigo.ipynb`) contiene el código completo, organizado en los mismos bloques de este informe, y genera las figuras aquí incluidas. Los procedimientos fueron:

- **Descriptiva:** medidas de tendencia central y dispersión con `describe()`, y gráficos según el tipo de variable (barras para el objetivo, histogramas para las variables continuas y un mapa de calor para las correlaciones).
- **Estimación:** intervalos de confianza para las medias mediante $\bar{x} \pm z_{0.975} \cdot EE$, con $EE = s/\sqrt{n}$, y para la proporción mediante la aproximación normal.
- **Prueba de hipótesis:** t de Welch (`scipy.stats.ttest_ind, equal_var=False`), prueba χ^2 de independencia (`scipy.stats.chi2_contingency`) y una prueba z de dos proporciones, todas con $\alpha = 0,05$.

6. Interpretación preliminar de resultados

(15 pts) Presenten interpretaciones preliminares claras y coherentes, vinculando los resultados obtenidos con el problema de decisión bajo incertidumbre.

De lo anterior se desprenden varias lecturas para el problema de otorgamiento de crédito. La más sólida tiene que ver con el comportamiento de pago, es decir, el historial de atrasos discrimina con fuerza el incumplimiento (riesgo relativo de 5,1 veces), y la edad aporta una señal adicional, más tenue, según la cual los clientes jóvenes resultan más riesgosos. El ingreso, en cambio, casi no se asocia de forma lineal con el objetivo ($r \approx -0,02$), lo que sugiere mirar el comportamiento crediticio antes que el nivel de ingreso a la hora de construir el modelo.

Quedan dos advertencias para las fases siguientes. El desbalance del objetivo (6,7% de morosos) obliga a evaluar los modelos con métricas sensibles a la clase minoritaria y no solo con la exactitud. Y la casi-colinealidad entre las variables de atrasos desaconseja incluirlas todas a la vez. Son hipótesis de trabajo; las evaluaciones posteriores dirán si se sostienen.

7. Presentación formal del informe

(15 pts) Verifiquen redacción formal, uso adecuado de lenguaje estadístico y cumplimiento del formato solicitado antes de subir el PDF a Canvas.

Este informe se redactó en un registro formal, con uso preciso de lenguaje estadístico (estimación puntual, intervalo de confianza, valor p , nivel de significancia, tamaño del efecto) y siguiendo la estructura de la plantilla solicitada. Antes de la entrega final, el equipo debe verificar que los datos del encabezado (integrantes, docente, fecha y repositorio) estén completos, que las figuras y tablas se referencien correctamente en el texto y que el documento se exporte en **formato PDF** para su carga en Canvas.

8. Participación en el foro

La actividad contempla publicar el producto en el foro de la semana y comentar al menos dos publicaciones de otros grupos. A continuación se incluye el **aporte inicial** preparado por el equipo y dos **comentarios** a pares.

8.1 Aporte inicial

Asunto: Ficha descriptiva - Give Me Some Credit (riesgo crediticio).

Compartimos nuestra aproximación inicial. Elegimos un conjunto del ámbito financiero sobre riesgo de crédito: 150.000 prestatarios descritos por 11 variables, con el objetivo de anticipar si una persona incurrirá en un atraso grave (90+ días) en dos años. Lo más interesante de la exploración: (1) todas las variables predictoras son numéricas, sin categóricas multinivel, así que el desafío no estará en codificar categorías sino en tratar outliers y datos faltantes (el ingreso tiene cerca de 20% de faltantes); (2) las tres variables de atrasos están casi perfectamente correlacionadas entre sí ($r \approx 0,99$), lo que anticipa un problema de multicolinealidad; y (3) la morosidad baja con la edad (de 11,7% en menores de 30 a 2,0% en mayores de 75), relación que confirmamos con una prueba t ($p < 0,0001$). Dejamos una duda para discutir: dado que las correlaciones lineales de todas las variables con el objetivo son débiles ($|r| < 0,13$), ¿conviene confiar solo en la correlación para seleccionar variables, o podría haber relaciones no lineales que se nos escapan? Agradecemos sus comentarios.

8.2 Comentarios a otros grupos

Comentario 1 (a un grupo con un dataset de salud con datos faltantes): “Muy clara su ficha. Nos llamó la atención que, igual que en nuestro conjunto, tienen una variable con muchos datos faltantes. ¿Han pensado si el faltante es aleatorio (MCAR) o si depende de otra variable? En nuestro caso eso cambia bastante la estrategia de imputación que usaríamos más adelante. Sugerimos agregar el porcentaje de faltantes por variable a la ficha, ayuda a dimensionar el problema.”

Comentario 2 (a un grupo con variables fuertemente correlacionadas): “Buen trabajo identificando las relaciones. Vemos que tienen dos variables muy correlacionadas, parecido a nuestro caso con las variables de atrasos ($r \approx 0,99$). Una sugerencia: clasifiquen explícitamente cada variable por tipo en una tabla; nos sirvió para detectar que casi todo nuestro conjunto era numérico y anticipar que el preprocesamiento se enfocaría en outliers más que en categorías.”

Bibliografía

- [1] Kaggle (2011). *Give Me Some Credit*. <https://www.kaggle.com/c/GiveMeSomeCredit>
- [2] Virtanen, P. et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261-272.

- [3] McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proc. 9th Python in Science Conf.*, 56-61.