

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 2

Práctica de Modelamiento Predictivo

Informe de práctica grupal · sin ponderación (formativa)

Ttulo del proyecto:	Análisis del Riesgo Crediticio
Integrantes:	«nombres completos (3-4 integrantes)»
Dataset:	Give Me Some Credit (Kaggle, 2011)
Docente:	«nombre del docente»
Fecha:	«dd/mm/aaaa»
Repositorio GitHub:	`https://github.com/usuario/repositorio`

Información de la evaluación

Fase: 3: Desarrollo (práctica previa a la Fase 4) **Ponderación:** 0 % (formativa, con retroalimentación)
Entregables: Notebook `.ipynb` ejecutable · este informe breve (opcional)
Resultado de aprendizaje: RA3 (se practica). **Prerrequisitos:** Sumativas 1 y 2.

Conexión con evaluaciones anteriores

Esta práctica reutiliza los hallazgos de S1 (análisis exploratorio e inferencial) y S2 (validación por remuestreo) para construir un primer modelo de clasificación. Es una versión **simplificada**: un solo modelo logístico, imputación simple y sin bootstrap. Su propósito es ensayar el flujo completo de modelamiento y recibir retroalimentación antes de la Sumativa 3, identificando errores a tiempo.

Índice

1 Preparación de datos para el modelamiento **2**
1.1 Referencia a los hallazgos de S1 y S2 . . . 2
1.2 Tratamiento de datos y partición . . . 2

2 Modelo de regresión logística **3**
2.1 Selección de variables . . . 3
2.2 Ajuste e interpretación de coeficientes . . . 4
2.3 Diagnóstico de multicolinealidad . . . 4

3 Evaluación de desempeño **4**
3.1 Matriz de confusión y métricas . . . 5
3.2 Curva ROC y AUC . . . 5

4 Síntesis y reflexión **6**

5 Bibliografía **7**

1. Preparación de datos para el modelamiento

(20 pts) Documente qué trae de S1 y S2, y qué tratamiento de datos aplicó. En la formativa basta una estrategia simple de faltantes.

1.1 Referencia a los hallazgos de S1 y S2

El punto de partida de esta formativa no es el dato crudo, sino el conocimiento acumulado en las dos sumativas previas. En S1 se caracterizó el conjunto *Give Me Some Credit*, el cual tiene 150.000 solicitantes de crédito, una variable objetivo binaria (morosidad grave a dos años) con un fuerte desbalance de clases (∼6,7 % de casos positivos), y un pequeño número de problemas de calidad que condicionan cualquier modelamiento posterior. Concretamente, S1 identificó faltantes en dos variables, el ingreso mensual, con cerca de un 20 % de vacíos, y el número de dependientes, con un 2,6 %, valores atípicos en las variables de atrasos (los códigos 96 y 98, que no representan un conteo real de atrasos sino una marca administrativa) y colas pesadas en la utilización de líneas y el ratio de deuda. Desde el punto de vista inferencial, S1 destacó como señales de riesgo la utilización de crédito, el historial de atrasos y, con relación negativa, la edad y el ingreso.

S2 aportó la validación a esas señales, es decir, mediante remuestreo bootstrap, verificó cuáles de las correlaciones observadas en S1 eran **estables**, es decir, cuáles mantenían su signo y magnitud al recalcularse sobre miles de remuestras del conjunto original y cuáles eran frágiles. La utilización, los atrasos de 30-59 y 90+ días y la edad resultaron estables (sus intervalos de confianza del 95 % no cruzaban el cero), mientras que el ingreso y el ratio de deuda mostraron correlaciones débiles y poco robustas. Esta distinción es la que guía, más abajo, la selección de variables del modelo. No se eligen las variables por intuición, sino por evidencia validada.

1.2 Tratamiento de datos y partición

Desde S1 hay tres decisiones de limpieza a tener en cuenta, por coherencia con el análisis previo. La eliminación del único registro con edad cero (un valor imposible), el acotamiento de los códigos 96/98 de las variables de atrasos a su máximo legítimo, lo que limita su influencia sin descartar los casos afectados y el recorte al percentil 99 de las colas de utilización y ratio de deuda. Sobre los valores faltantes, y dado que esta es una evaluación formativa orientada a ensayar el flujo, se adoptó una estrategia **simple**, es decir, la imputación por la mediana. La mediana es una elección razonable en este contexto porque es robusta a la asimetría del ingreso (una media se vería arrastrada por la cola de ingresos altos) y porque preserva el tamaño completo de la muestra, a diferencia de eliminar los casos incompletos. Su limitación conocida, que reduce artificialmente la variabilidad de la variable imputada, se asume como costo aceptable en esta fase, y se aborda con mayor rigor en S3.

La partición del conjunto se hizo en un 70 % de entrenamiento y un 30 % de prueba, **estratificada** por la variable objetivo. La estratificación es importante aquí precisamente por el desbalance. Nos garantiza que ambos subconjuntos conserven la misma proporción de morosos (∼6,7 %), evitando que el azar deje una partición con muy pocos casos positivos, lo que distorsionaría tanto el ajuste como la evaluación. Por último, los predictores se estandarizaron (media cero, desviación uno), de modo que los coeficientes del modelo y sus odds ratios se interpreten por desviación estándar y sean directamente comparables entre sí, independientemente de la escala original de cada variable. La Figura 1 ilustra, para dos de las variables seleccionadas, por qué separan bien las clases, es decir, los morosos concentran una utilización de crédito notablemente más alta, mientras que la edad muestra el patrón inverso y más suave que anticipa su rol protector.

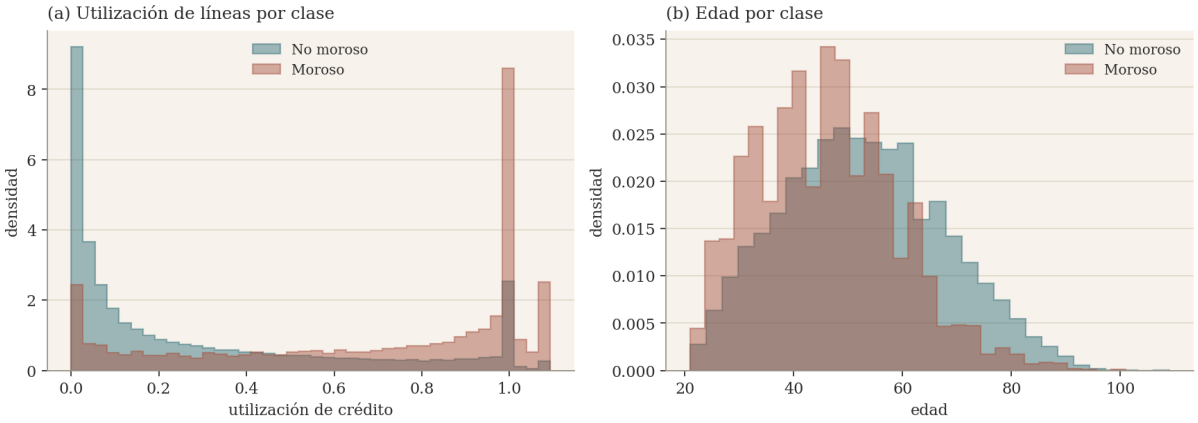


Figura 1: Distribución de dos predictores por clase. (a) La utilización de crédito es marcadamente mayor entre los morosos, lo que anticipa su fuerza como predictor. (b) La edad muestra una separación más leve, coherente con su papel de factor protector.

Qué se ampliará en la Sumativa 3

En S3 se reemplazará la mediana por **imputación mediante regresión lineal múltiple**, que aprovecha la estructura de correlaciones de S1 para predecir cada faltante a partir de otras variables, y se compararán sistemáticamente tres estrategias de tratamiento de faltantes (eliminación, imputación simple e imputación por regresión) analizando su efecto sobre el tamaño muestral, la distribución y las correlaciones.

2. Modelo de regresión logística

(40 pts) Justifique la selección de variables con S1/S2, ajuste el modelo, interprete los odds ratios y diagnostique la multicolinealidad.

2.1 Selección de variables

A partir de la matriz de correlaciones de S1 y su validación en S2, se seleccionaron cuatro predictores, todos con correlaciones que S2 confirmó como estables (Tabla 1). El criterio fue doble. Primero, que la variable mostrara una asociación relevante con la morosidad en S1, y segundo, que esa asociación resistiera el remuestreo de S2. Bajo ese filtro, ingreso y ratio de deuda quedaron fuera pese a estar disponibles, porque S2 los caracterizó como correlaciones débiles e inestables. Incluirlos habría añadido ruido sin aportar capacidad predictiva confiable. Esta es la lógica de *selección informada por el dominio* que el apunte del curso plantea como uno de los enfoques válidos de selección de variables (Maidana, 2026).

Tabla 1: Variables seleccionadas y el hallazgo de S1/S2 que respalda cada una.

Variable	Corr. S1	IC bootstrap S2	Fundamento
Utilización de líneas	+0,30	[0,29; 0,31]	Predictor más fuerte; a mayor uso del crédito disponible, mayor presión financiera.
Atrasos 30-59 días	+0,13	[0,12; 0,14]	Historial de atrasos recientes; señal directa del comportamiento de pago.
Atrasos 90+ días	+0,12	[0,11; 0,13]	Atrasos graves; aporta información independiente de los de 30-59.
Edad	−0,11	[−0,12; −0,10]	Factor protector; los clientes de mayor edad incumplen menos.

2.2 Ajuste e interpretación de coeficientes

El modelo se ajustó con la biblioteca `statsmodels` (Seabold & Perktold, 2010) sobre las variables estandarizadas, agregando una constante. La interpretación de los odds ratios es el corazón del análisis, porque traduce los coeficientes a un lenguaje de negocio. La **utilización** es el mayor factor de riesgo, con un odds ratio cercano a 2,3, cada desviación estándar adicional en el uso del crédito disponible más que duplica las probabilidades relativas (odds) de morosidad. Esto es coherente con la intuición financiera, ya que un cliente que ha agotado su crédito disponible se encuentra bajo mayor tensión. El **historial de atrasos** sigue en importancia, tanto la ventana de 30-59 días como la de 90+ días tienen odds ratios superiores a uno y, notablemente, aportan de forma independiente, haber tenido atrasos leves y atrasos graves son señales distintas, no redundantes. La **edad**, en cambio, actúa como factor protector, es decir, su odds ratio cercano a 0,8 indica que cada desviación estándar adicional de edad reduce las odds de morosidad en torno a un 20 %. Las cuatro variables resultan estadísticamente significativas ($p < 0{,}05$).

2.3 Diagnóstico de multicolinealidad

Un supuesto que conviene verificar en toda regresión con varios predictores es la ausencia de multicolinealidad, es decir, que las variables no estén tan correlacionadas entre sí como para volver inestables los coeficientes. Para ello se calcularon los factores de inflación de varianza (VIF) de las cuatro variables. Todos quedaron holgadamente por debajo del umbral habitual de 5, de hecho, cercanos a 1, lo que descarta cualquier problema de colinealidad y confirma que cada predictor aporta información independiente. Este resultado es consistente con S2, que ya había mostrado que estas cuatro correlaciones eran estables y no se solapaban.

Qué se ampliará en la Sumativa 3

En S3 se construirán **tres modelos** con criterios de selección distintos, uno guiado por el dominio (S1/S2), uno por selección *stepwise* según AIC/BIC, y un modelo reducido, se aplicará **bootstrap** a los coeficientes del mejor modelo para construir intervalos de confianza del 95 % y verificar su estabilidad, y el diagnóstico se ampliará con la linealidad en el logit y la identificación de observaciones influyentes.

3. Evaluación de desempeño

(30 pts) Reporte la matriz de confusión, las métricas de clasificación y la curva ROC. Interprete cada una en el contexto del problema.

3.1 Matriz de confusión y métricas

Con un umbral de decisión de 0,5, el modelo alcanza una **accuracy** elevada, cercana al 93,5 %. Sin embargo, esta cifra es profundamente engañosa y su interpretación poco crítica es uno de los errores más comunes en clasificación con clases desbalanceadas. La razón es aritmética, dado que solo el 6,7 % de los casos son morosos, un clasificador trivial que predijera "no moroso" para absolutamente todos los solicitantes alcanzaría por sí solo un 93 % de accuracy, sin haber detectado un solo moroso ni tener utilidad alguna. Por eso el análisis se apoya en métricas que sí distinguen el desempeño sobre la clase minoritaria, que es la relevante, como la **precision** (de los marcados como morosos, cuántos lo son realmente), el **recall** (de los morosos reales, cuántos detecta el modelo) y su media armónica, el **F1-score**.

En el contexto de riesgo crediticio, el **recall** es la métrica crítica. La asimetría de costos lo justifica, es decir, un falso negativo, aprobar a un cliente que luego incumple, suele llevar a una pérdida directa mucho mayor que un falso positivo, como rechazar a un buen cliente, cuyo costo es la ganancia no realizada. La Figura 2 muestra la matriz de confusión sobre el conjunto de prueba, y ahí aparece justamente el problema que hay que resolver, es decir, con umbral 0,5 y sin ponderación de clase, el modelo es muy conservador para marcar a alguien como moroso. De los 3.008 morosos reales en la prueba, detecta solo 237 (**recall** de apenas 7,9 %) y deja pasar a 2.771. Cuando sí marca a alguien como riesgoso acierta con más frecuencia (**precision** de 60,3 %), pero esa precisión alta no compensa la baja cobertura. Es el comportamiento esperable de un umbral fijo sin ajustar sobre una clase tan minoritaria, y es exactamente el motivo concreto por el que S3 incorporará ponderación de clase.

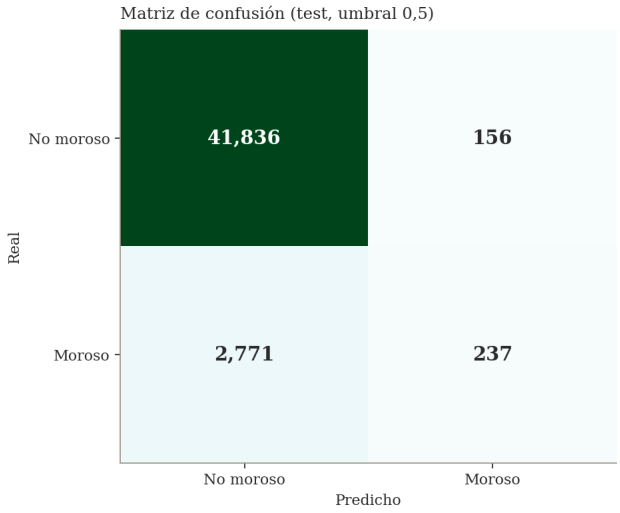


Figura 2: Matriz de confusión sobre el conjunto de prueba (umbral 0,5). Las filas son la clase real y las columnas la clase predicha; sin ponderación de clase, el modelo detecta muy pocos morosos reales (recall 7,9 %), aunque acierta con frecuencia cuando sí los marca.

3.2 Curva ROC y AUC

La métrica más informativa para resumir la capacidad discriminante del modelo, y la que no depende del umbral elegido, es el área bajo la curva ROC (AUC). El valor obtenido, 0,834, sitúa al modelo en el rango que la literatura considera *bueno* (Hosmer, Lemeshow & Sturdivant, 2013). Su interpretación es concreta e intuitiva. Si se toman al azar un cliente moroso y uno no moroso, el modelo asigna una mayor probabilidad de riesgo al moroso aproximadamente el 83 % de las veces. A diferencia de la accuracy, el AUC no se deja engañar por el desbalance, porque evalúa el ordenamiento de las probabilidades en lugar de las clasificaciones a un umbral fijo. La curva ROC (Figura 3) se aleja con claridad de la diagonal del clasificador aleatorio, lo

que confirma visualmente esa capacidad discriminante. Un AUC de este nivel, logrado con solo cuatro variables y un modelo lineal simple, constituye una buena base sobre la cual la Sumativa 3 buscará mejoras.

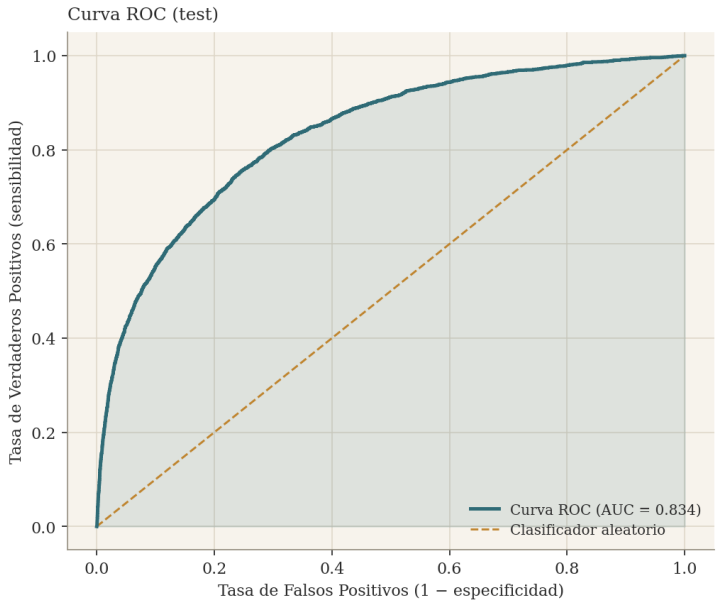


Figura 3: Curva ROC sobre el conjunto de prueba. El área bajo la curva (AUC) resume la capacidad del modelo para distinguir morosos de no morosos, independientemente del umbral de decisión.

Qué se ampliará en la Sumativa 3

En S3 se usará **ponderación por clase** (`class_weight`) para elevar el recall de la clase minoritaria, se compararán las curvas ROC de los tres modelos en un mismo gráfico para elegir el modelo final con criterio, y se analizará cómo la estrategia de imputación afecta al AUC y a los coeficientes.

4. Síntesis y reflexión

(10 pts) Cierre conectando explícitamente con S1 y S2, evalúe el desempeño y anticipe las mejoras concretas para S3.

Esta práctica permitió recorrer completamente el flujo de modelamiento predictivo que la Sumativa 3 pide en su forma extendida, es decir, preparar los datos apoyándose en los hallazgos previos, seleccionar variables con fundamento, ajustar un modelo de clasificación, interpretar sus coeficientes en clave de negocio, diagnosticar sus supuestos y evaluar su desempeño con las métricas adecuadas. La **conexión con S1** se determinó con la selección de variables y en el tratamiento de datos, es decir, las señales de riesgo, los faltantes y los outliers no se redescubrieron, sino que se heredaron del análisis exploratorio. La **conexión con S2** fue la que dio solidez a esas decisiones. La validación por bootstrap distinguió las correlaciones confiables de las frágiles, y esa distinción determinó qué variables entraron al modelo y cuáles quedaron fuera.

En cuanto al desempeño, la valoración es positiva pero tiene sus detalles. El AUC de 0,834 demuestra una capacidad discriminante real y buena, pero el modelo, tal como está, con umbral 0,5 y sin ponderación de clase, deja escapar a la gran mayoría de los morosos (recall de apenas 7,9 %), lo que en un contexto real sería muy costoso. Esa es, precisamente, la principal oportunidad de mejora identificada para S3. El principal aprendizaje conceptual de la formativa fue

comprender por qué la accuracy engaña con clases desbalanceadas y por qué el AUC y el recall son las métricas que verdaderamente importan en riesgo crediticio.

Con respecto a la **Sumativa 3**, esta formativa deja identificadas con claridad las mejoras a incorporar. Primero, hay que reemplazar la imputación por mediana con imputación por regresión y comparar estrategias. En segundo lugar, se debe construir y comparar tres modelos con criterios de selección distintos en lugar de uno solo. Tercero, aplicar bootstrap a los coeficientes para cuantificar su estabilidad. Y cuarto, incorporar ponderación de clase para mejorar el recall. La progresión S1 $\rightarrow$ S2 $\rightarrow$ S3 queda así encaminada, y esta formativa (y notebook) constituye la base directa sobre la que se construirá el proyecto final integrado.

5. Bibliografía

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning.* Springer.

Kaggle. (2011). *Give Me Some Credit* [Conjunto de datos]. `https://www.kaggle.com/c/GiveMeSomeCredit`

Little, R. J. A., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley.

Maidana, J. P. (2026). *Selección de variables y comparación de modelos* [Apunte del curso MCDI501]. Universidad Andrés Bello.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. *Proc. 9th Python in Science Conf.*, 92–96.

Recordatorio

Esta es una evaluación **formativa** sin ponderación. Su valor está en la retroalimentación, donde todas las decisiones metodológicas se fundamentan en S1 y S2, y el trabajo aquí realizado es la base directa de la Sumativa 3.