



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto: Análisis del Riesgo Crediticio
Integrantes: «nombres completos (3-4 integrantes)»
Dataset: Give Me Some Credit (Kaggle, 2011)
Docente: «nombre del docente»
Fecha: «dd/mm/aaaa»
Repositorio GitHub: <https://github.com/usuario/repositorio>

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información

Modalidad: Grupal (3–4 integrantes) **Ponderación:** 20 % de la nota final

Entregables: Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub

Resultado de aprendizaje (RA1): aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.

Indicadores: ID1.2, ID1.3, ID1.4.

Recuerden: los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

1	Preparación y carga de datos	2
2	Análisis exploratorio de datos	2
2.1	Estadística descriptiva	2
2.2	Análisis bivariado	3
3	Estimación de parámetros	4
4	Pruebas de hipótesis	5
4.1	Prueba 1: diferencia de edad entre morosos y no morosos	5
4.2	Prueba 2: asociación entre historial de atrasos y morosidad	6
5	Informe de avance del proyecto	6
6	Notebook y repositorio GitHub	6
7	Bibliografía	7

1. Preparación y carga de datos

(15 pts) Carga del dataset seleccionado en Python; verificación de estructura y tipos de variables; identificación y documentación de faltantes, duplicados e inconsistencias; limpieza básica y reporte inicial de calidad de los datos.

El proyecto utiliza el conjunto *Give Me Some Credit* (Kaggle, 2011), con 150.000 prestatarios y once variables. La variable objetivo, `SeriousDlqin2yrs`, indica si la persona registró un atraso grave de 90 o más días dentro de un horizonte de dos años. Los diez predictores son todos numéricos: utilización de líneas de crédito, edad, atrasos en tres tramos (30–59, 60–89 y 90 o más días), ratio de deuda, ingreso mensual, líneas y préstamos abiertos, préstamos inmobiliarios y número de dependientes.

La revisión de calidad muestra tres situaciones. El ingreso mensual concentra 29.731 valores faltantes (19,8 %) y el número de dependientes 3.924 (2,6 %); ninguna otra variable tiene vacíos (Figura 1b). Existen 609 filas duplicadas. Y aparecen valores poco plausibles: un registro con edad cero, los códigos 96 y 98 en las tres variables de atrasos, y colas muy largas en utilización, ratio de deuda e ingreso, con máximos de 50.708, 329.664 y 3.008.750 respectivamente. La Tabla 1 documenta el tratamiento de cada caso.

Tabla 1: Decisiones de limpieza y tratamiento de datos.

Situación	Decisión
Edad igual a 0 (1 registro)	Se descarta por ser un valor imposible.
Códigos 96 y 98 en los atrasos	Se tratan como códigos especiales y se excluyen al analizar esas variables.
Ingreso faltante (19,8 %) y dependientes (2,6 %)	Se trabaja con casos completos en esta fase; la imputación se aborda en el modelamiento.
Outliers en utilización, ratio de deuda e ingreso	Se conservan; para el ingreso se usa la mediana como referencia robusta y en los gráficos se recorta la cola alta solo para visualizar.
609 filas duplicadas	Se documentan y se conservan en esta fase descriptiva. Como los predictores son de baja resolución (conteos y variables acotadas), filas idénticas pueden corresponder a solicitantes distintos con el mismo perfil, así que su eliminación no es evidente y se difiere al modelamiento, donde se evaluará su efecto sobre el desempeño.

2. Análisis exploratorio de datos

(15 pts) Estadística descriptiva de variables numéricas y categóricas con visualizaciones adecuadas; análisis bivariado (correlaciones y relaciones relevantes) con interpretación de cada hallazgo en el contexto del problema.

2.1 Estadística descriptiva

La Tabla 2 resume la tendencia central, la dispersión y la asimetría de las variables. La edad es la única con forma casi simétrica (media 52,30, mediana 52 y asimetría 0,19). En el ingreso, el ratio de deuda y la utilización la media supera con holgura a la mediana y la asimetría supera 95, lo que confirma distribuciones muy sesgadas a la derecha con valores extremos. La fuerte asimetría de las tres variables de atrasos (sobre 22) está inflada además por los códigos especiales 96 y 98. La variable objetivo está desbalanceada: solo el 6,7 % de los clientes son morosos (Figura 1a), una razón cercana a 1 de cada 14.

Tabla 2: Medidas descriptivas de las variables numéricas (150.000 observaciones).

Variable	Media	Mediana	Desv. est.	Mínimo	Máximo	Asimetría
Utilización de crédito	6,05	0,15	249,76	0	50.708	97,63
Edad	52,30	52,00	14,77	0	109	0,19
Atrasos 30–59 días	0,42	0,00	4,19	0	98	22,60
Ratio de deuda	353,01	0,37	2.037,82	0	329.664	95,16
Ingreso mensual	6.670,22	5.400	14.384,67	0	3.008.750	114,04
Líneas/préstamos abiertos	8,45	8,00	5,15	0	58	1,22
Atrasos 90+ días	0,27	0,00	4,17	0	98	23,09
Préstamos inmobiliarios	1,02	1,00	1,13	0	54	3,48
Atrasos 60–89 días	0,24	0,00	4,16	0	98	23,33
N.º de dependientes	0,76	0,00	1,12	0	20	1,59




Figura 1: (a) Distribución de la variable objetivo. (b) Porcentaje de datos faltantes por variable.

La Figura 2 confirma estas formas: edad casi simétrica, ingreso concentrado en valores bajos con cola larga, y número de líneas acumulado en cifras pequeñas.




Figura 2: Distribución de tres variables numéricas, con su media o mediana de referencia.

2.2 Análisis bivariado

La matriz de correlaciones (Figura 3) muestra que las tres variables de atrasos están casi perfectamente correlacionadas entre sí (r entre 0,98 y 0,99): miden en la práctica el mismo comportamiento, lo que anticipa multicolinealidad. Las correlaciones lineales de los predictores con el objetivo son débiles (todas con $|r| < 0,13$).




Figura 3: Matriz de correlaciones entre las variables numéricas (triángulo inferior).

Como el conjunto no trae variables categóricas, se construyeron tres a partir de las numéricas: tramo etario, cuartil de ingreso e indicador de atraso de 30 a 59 días. La Figura 4 relaciona las dos primeras con la morosidad. La tasa cae de forma sostenida con la edad, del 11,7 % en menores de 30 años al 2,0 % en mayores de 75. Por ingreso también descende de forma monótona, del 9,2 % en el cuartil más bajo al 4,6 % en el más alto. Este último patrón es relevante: aunque la correlación lineal del ingreso con el objetivo es casi nula, por cuartiles aparece una relación clara, señal de que el vínculo existe pero no es lineal y queda oculto por los valores extremos.




Figura 4: Tasa de morosidad por tramo etario y por cuartil de ingreso, con la media global de referencia.

3. Estimación de parámetros

(15 pts) Para al menos 3 variables numéricas relevantes: estimación puntual e intervalos de confianza al 95 %; interpretación de los intervalos, justificación de los métodos utilizados y discusión de limitaciones.

Se estimaron cuatro parámetros poblacionales con un nivel de confianza del 95 % (Tabla 3). Para

las medias de tres variables numéricas se empleó el intervalo basado en la aproximación normal, $\bar{x} \pm z_{0,975} \text{EE}$ con $\text{EE} = s/\sqrt{n}$, justificado por el Teorema Central del Límite dado el gran tamaño muestral (Wasserman, 2004). Para la proporción de morosidad se usó la misma aproximación normal (método de Wald), $\hat{p} \pm z_{0,975} \sqrt{\hat{p}(1 - \hat{p})/n}$, que es el procedimiento visto en clase.

Tabla 3: Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación	IC 95 %	Método
Edad media (años)	52,30	[52,22; 52,37]	Normal (TCL)
Ingreso mensual medio	6.670,22	[6.588,9; 6.751,5]	Normal (TCL), $n = 120.269$
Líneas y préstamos (media)	8,45	[8,43; 8,48]	Normal (TCL)
Proporción de morosidad	0,0668	[0,0656; 0,0681]	Normal (Wald)

Los intervalos son estrechos, consecuencia directa del tamaño de la muestra: con cientos de miles de observaciones, el error estándar es pequeño. Con un 95 % de confianza, la edad media poblacional se ubica entre 52,22 y 52,37 años y la proporción de morosos entre 6,56 % y 6,81 %.

La estimación tiene límites que conviene declarar. La media del ingreso queda inflada por los valores extremos (hasta tres millones) y resulta poco representativa del cliente típico, cuya mediana es 5.400; por eso el intervalo de la media debe leerse con cautela y se acompaña de la mediana como referencia. Además, esa estimación usa solo los casos con dato, de modo que un 19,8 % de los registros queda fuera; si el faltante no fuera aleatorio, podría introducir sesgo. Por último, los intervalos asumen que la muestra es representativa de la población de solicitantes.

Complemento (no evaluado). Para proporciones extremas o muestras pequeñas, el intervalo de Wilson ofrece mejor cobertura que el de Wald; con el tamaño de muestra de este estudio ambos coinciden. El tema se desarrolla en el apunte complementario del curso y no forma parte de los criterios evaluados.

4. Pruebas de hipótesis

(15 pts) Al menos 2 pruebas pertinentes al problema: formulación de H_0 y H_1 , nivel de significancia justificado, verificación de supuestos, ejecución, interpretación de resultados e implicancias prácticas.

Se aplicaron dos pruebas con nivel de significancia $\alpha = 0,05$, valor habitual en estudios aplicados que equilibra los errores de tipo I y II.

4.1 Prueba 1: diferencia de edad entre morosos y no morosos

Se contrasta si la edad media difiere entre ambos grupos:

$$H_0 : \mu_{\text{moroso}} = \mu_{\text{no moroso}} \quad \text{vs.} \quad H_1 : \mu_{\text{moroso}} \neq \mu_{\text{no moroso}}.$$

Supuestos. Los grupos son independientes. La edad es aproximadamente simétrica en ambos (asimetría de 0,46 en morosos y 0,16 en no morosos) y, con tamaños de 10.026 y 139.974, el Teorema Central del Límite respalda el uso de la prueba t . Como los grupos tienen tamaños muy dispares y desviaciones estándar distintas (12,9 y 14,8 años), no se asume igualdad de varianzas y se usa la prueba t de Welch, que estima el error estándar por separado en cada grupo (Welch, 1947).

Resultado. La edad media es 45,93 años en los morosos y 52,75 en los no morosos. El estadístico es $t = -50,58$ con $p < 0,001$, de modo que se rechaza H_0 . El tamaño del efecto es moderado (d de Cohen = $-0,47$). La Figura 5a muestra la diferencia. En términos del negocio, la edad discrimina riesgo, pero por sí sola no separa de forma nítida a morosos de no morosos.

Complemento (no evaluado). La igualdad de varianzas puede contrastarse formalmente con la prueba de Levene, y la elección entre la prueba t estándar y la de Welch admite una discusión más fina. Ambos temas se desarrollan en el apunte complementario del curso.

4.2 Prueba 2: asociación entre historial de atrasos y morosidad

Se contrasta la independencia entre haber registrado un atraso de 30 a 59 días y la morosidad grave:

$$H_0 : \text{atraso 30–59 y morosidad son independientes} \quad \text{vs.} \quad H_1 : \text{están asociados.}$$

Supuestos. Se usa la prueba χ^2 de independencia sobre una tabla de 2×2 . La frecuencia esperada mínima es 1.565, muy por encima del umbral de 5, así que el supuesto se cumple.

Resultado. La morosidad alcanza el 20,4% entre quienes tuvieron algún atraso de 30 a 59 días y el 4,0% entre quienes no (Figura 5b). La asociación es significativa ($\chi^2 = 8.709,9$; gl = 1; $p < 0,001$), con una intensidad moderada (V de Cramér = 0,24). El riesgo relativo es de 5,1 y la razón de momios de 6,2. La implicancia práctica es directa: el comportamiento de pago pasado es el predictor más informativo del incumplimiento y debería pesar fuerte en cualquier modelo de *scoring*.




Figura 5: (a) Distribución de la edad por grupo (rombo: media). (b) Tasa de morosidad según el historial de atrasos de 30 a 59 días.

5. Informe de avance del proyecto

Introducción al problema, descripción de métodos aplicados, resumen de resultados, interpretaciones preliminares y próximos pasos del proyecto.

El problema es de decisión bajo incertidumbre: estimar, antes de aprobar un crédito, la probabilidad de que un solicitante caiga en morosidad grave. En esta fase caracterizamos el conjunto con estadística descriptiva y gráficos por tipo de variable, estimamos parámetros poblacionales con intervalos de confianza y contrastamos dos hipótesis pertinentes al negocio mediante la prueba t de Welch y la prueba χ^2 de independencia.

Los resultados ofrecen tres lecturas. El historial de atrasos es la señal más fuerte: un atraso previo quintuplica el riesgo. La edad aporta una señal más tenue, con los jóvenes en mayor riesgo, y el ingreso muestra una relación monótona por cuartil pese a su correlación lineal casi nula. Como advertencia, el desbalance del objetivo (6,7% de morosos) exigirá evaluar los modelos con métricas sensibles a la clase minoritaria, y la casi-colinealidad entre las variables de atrasos obliga a no incluirlas todas juntas. Los próximos pasos son la imputación del ingreso, el tratamiento de outliers y duplicados, y el entrenamiento de modelos de clasificación con técnicas de remuestreo.

6. Notebook y repositorio GitHub

(6 pts, junto al informe) Notebook reproducible, documentado y coherente con el informe; repositorio

GitHub enlazado en el informe.

Todo el análisis se realizó en Python con `pandas` (McKinney, 2010), `numpy` y `scipy` (Virtanen et al., 2020), y `matplotlib`. El cuaderno `Sumativa1_GiveMeSomeCredit_Codigo.ipynb` sigue el mismo orden de este informe, genera las figuras y tablas aquí incluidas y fija la semilla 42 para asegurar la reproducibilidad. El código está disponible en el repositorio enlazado en la portada.

7. Bibliografía

Referencias en formato APA 7.^a edición, citadas explícitamente en el texto.

- Kaggle. (2011). *Give Me Some Credit* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/c/GiveMeSomeCredit>
- McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Wasserman, L. (2004). *All of statistics: A concise course in statistical inference*. Springer.
- Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35. <https://doi.org/10.1093/biomet/34.1-2.28>