MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal · 20 %

Título del proyecto:	Análisis del Riesgo Crediticio
Integrantes:	«nombres completos (3-4 integrantes)»
Dataset:	Give Me Some Credit (Kaggle, 2011)
Docente:	«nombre del docente»
Fecha:	«dd/mm/aaaa»
Repositorio GitHub:	`https://github.com/usuario/repositorio`

Información de la evaluación

Fase del proyecto: Fase 3: Desarrollo del proyecto **Ponderación:** 20 % de la nota final
Entregables: Informe PDF (máx. 7 págs.) · Notebook `.ipynb` · Repositorio GitHub (S1, S2 y resultados validados)
Resultado de aprendizaje (RA2): implementar métodos computacionales de simulación y remuestreo para apoyar la toma de decisiones.
Indicadores: ID2.1, ID2.2, ID2.3. **Prerrequisito:** Sumativa 1.

Conexión con evaluaciones anteriores

Todo el trabajo se construye sobre los resultados propios de la Sumativa 1: los parámetros estimados y sus intervalos clásicos, la prueba t de Welch para la edad, la prueba χ^2 del historial de atrasos y las correlaciones entre variables. Cada sección valida o pone a prueba uno de esos resultados.

Índice

1 Validación de resultados de S1 mediante bootstrap **2**

2 Validación de pruebas de hipótesis mediante permutación **2**

3 Evaluación de estabilidad de correlaciones **3**

4 Simulación Monte Carlo basada en parámetros de S1 **4**
4.1 Escenarios por tamaño de cartera 4

5 Análisis de robustez **5**

6 Preparación para la Sumativa 3 **5**

7 Bibliografía **6**

1. Validación de resultados de S1 mediante bootstrap

(18 pts) Para al menos 3 parámetros estimados en S1: bootstrap no paramétrico (≥10.000 remuestras), IC por método percentil y BCa, comparación sistemática con el IC clásico y visualización de la distribución bootstrap. Analicen discrepancias y la confiabilidad de cada método según sus supuestos.

Aplicamos bootstrap no paramétrico (Efron & Tibshirani, 1993) con 10.000 remuestras a tres parámetros de S1: la edad media, el ingreso mensual medio y el número medio de líneas y préstamos. Para cada uno calculamos el intervalo percentil y el intervalo BCa, que corrige sesgo y aceleración (Efron, 1987), y los comparamos con el intervalo clásico de S1 (Tabla 1). Los tres métodos se basan en supuestos distintos, el clásico asume que la distribución de la media muestral es aproximadamente normal, el percentil supone que la distribución bootstrap está centrada y es simétrica y el BCa relaja ese supuesto corrigiendo el sesgo (z_0) y la asimetría o aceleración (a). La Figura 1 muestra las distribuciones bootstrap con los tres intervalos superpuestos.

Tabla 1: Intervalos de confianza al 95 %: clásico de S1, percentil y BCa.

Parámetro	**Clásico (S1)**	**Percentil**	**BCa**
Edad media (años)	[52,22; 52,37]	[52,22; 52,37]	[52,22; 52,37]
Ingreso mensual medio	[6.588,9; 6.751,5]	[6.595; 6.756]	[6.604; 6.774]
Líneas y préstamos (media)	[8,43; 8,48]	[8,43; 8,48]	[8,43; 8,48]

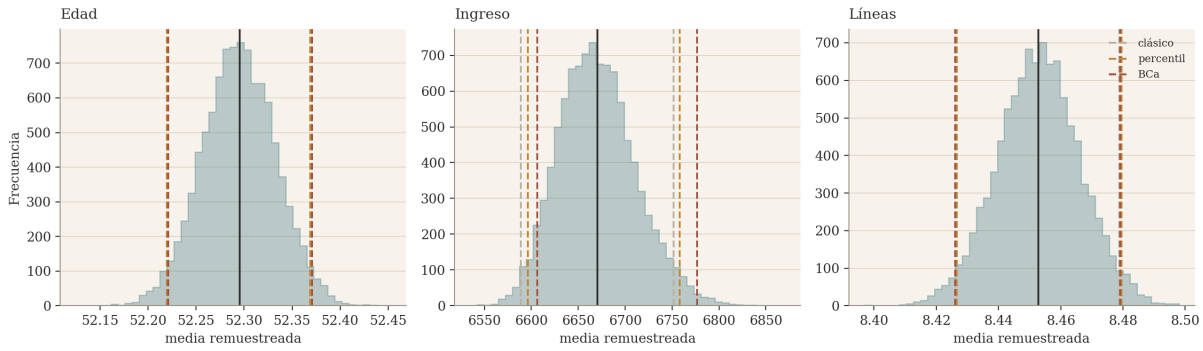


Figura 1: Distribuciones bootstrap de las tres medias (10.000 remuestras) con los intervalos clásico, percentil y BCa. La línea sólida marca la estimación puntual.

En la edad y en el número de líneas los factores de corrección son cercanos a cero (z_0 de 0,022 y 0,015, a por debajo de 0,001), de modo que los tres intervalos se superponen y el clásico basta. En el ingreso son mayores ($z_0 = 0{,}046$ y $a = 0{,}055$), porque la cola larga introduce sesgo y asimetría en la distribución bootstrap. Por eso su BCa se desplaza a la derecha respecto del clásico, de 6.589 a 6.604 en el extremo inferior y de 6.752 a 6.774 en el superior. Esa corrección existe, pero en términos prácticos es pequeña frente al tamaño de la muestra (el intervalo se mueve unas 20 unidades sobre una media de 6.670). Cuando la variable es asimétrica el BCa es el más confiable. Cuando es simétrica, los tres coinciden.

2. Validación de pruebas de hipótesis mediante permutación

(15 pts) Seleccionen al menos una prueba de S1; implementen un test de permutación (≥10.000 permutaciones); comparen el valor p de permutación con el paramétrico original y discutan la concordancia entre ambos enfoques.

Validamos la prueba t de Welch de S1, que comparó la edad media entre morosos y no morosos, con un test de permutación de 10.000 repeticiones (Good, 2005). Bajo la hipótesis nula de igualdad mezclamos las etiquetas de grupo y recomputamos la diferencia de medias (morosos

menos no morosos) en cada repetición. La diferencia observada es de −6,82 años, es decir, los morosos son en promedio casi siete años más jóvenes. La distribución nula se concentra cerca de cero, con amplitud menor a un año (Figura 2), y ninguna de las 10.000 permutaciones se acerca al valor observado, de modo que el valor p de permutación es menor que 0,001. Coincide con el resultado paramétrico de S1. La concordancia es esperable, con una diferencia tan marcada y muestras grandes, ambos enfoques llegan a la misma conclusión, y la permutación confirma que el resultado no depende del supuesto de normalidad.

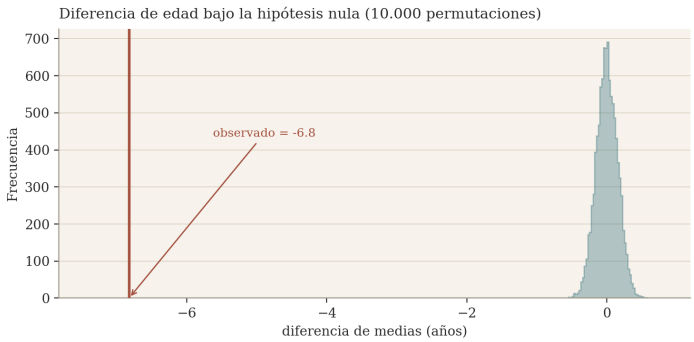


Figura 2: Distribución de la diferencia de edad bajo la hipótesis nula (10.000 permutaciones). El valor observado queda fuera del rango generado por el azar.

3. Evaluación de estabilidad de correlaciones

(6 pts) Seleccionen 3 a 5 correlaciones relevantes de S1 y evalúen su estabilidad mediante IC bootstrap al 95 %, identificando correlaciones robustas e inestables.

Evaluamos cinco correlaciones de S1 con intervalos bootstrap al 95 % (3.000 remuestras de filas), resumidas en la Figura 3. Una precaución que es clave, en las variables de atrasos, los códigos 96 y 98 (269 filas) no son conteos reales. Sin excluirlos, esas filas idénticas y extremas producen una correlación falsa de 0,98 entre atrasos de 30-59 y de 90+ días, por lo tanto excluyéndolos, la correlación real es 0,22. Usamos el valor limpio.

Con ese cuidado, cuatro correlaciones son robustas: atrasos 30-59 vs 90+ ($r = 0{,}22$), líneas con préstamos inmobiliarios ($r = 0{,}43$) y edad con morosidad ($r = -0{,}12$) tienen intervalos estrechos que no cruzan el cero, y edad con ingreso ($r = 0{,}04$) es robusta pero muy débil. La única inestable es utilización con ratio de deuda, su intervalo $[-0{,}000;\ 0{,}012]$ incluye el cero. La "casi perfecta" colinealidad de 0,98 reportada en S1 era, entonces, un artefacto de los códigos, en este caso, la Sección 5 lo cuantifica.

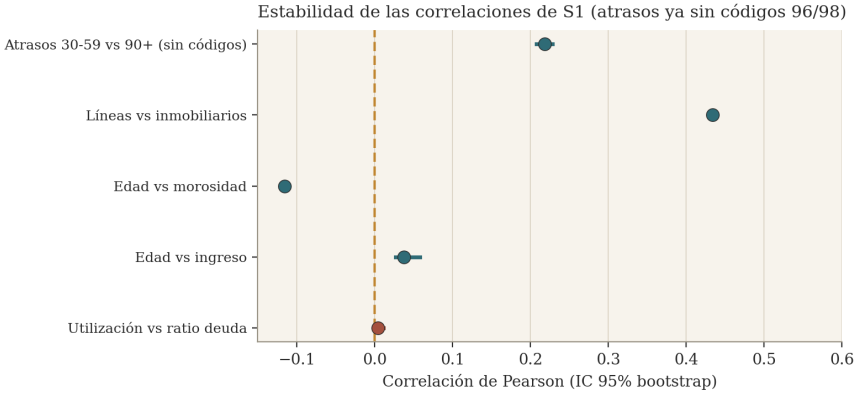


Figura 3: Intervalos bootstrap al 95 % de cinco correlaciones de S1, con las variables de atrasos ya sin los códigos 96 y 98. En color oscuro la inestable, cuyo intervalo cruza el cero.

4. Simulación Monte Carlo basada en parámetros de S1

(24 pts) Diseñen una simulación relevante para el problema, usando exclusivamente parámetros estimados en S1; implementen con ≥10.000 iteraciones, evalúen convergencia, calculen estadísticos relevantes e interpreten los escenarios simulados en relación con el fenómeno real.

Diseñamos una simulación Monte Carlo (Robert & Casella, 2004) pertinente a la decisión de cartera, usando solo parámetros de S1. Cada cliente de una cartera de 1.000 tiene un atraso previo de 30 a 59 días con la proporción observada en S1 ($q = 0{,}158$) y cae en morosidad con la tasa que S1 estimó para cada grupo, es decir, 20,4 % si tuvo atraso y 4,0 % si no. Simulamos 10.000 carteras y registramos su tasa de morosidad.

La tasa media simulada es 6,6 %, igual a la que implican los parámetros y muy cercana a la morosidad global de S1 (6,68 %), lo que valida la coherencia del modelo. La media converge a ese valor después de algunos miles de carteras (Figura 4b), señal de que 10.000 iteraciones bastan. El error estándar de Monte Carlo de la media es de apenas 0,008 puntos porcentuales, lo que confirma la precisión de la estimación. La distribución de la Figura 4a indica que, con 95 % de probabilidad, la morosidad de una cartera cae entre 5,1 % y 8,2 %, y en el peor 1 % de los escenarios alcanza el 8,5 %. La probabilidad de superar el 8 % es de 3,7 %. Para la gestión, esto cuantifica el riesgo de cola: aunque la morosidad esperada es baja, una cartera concreta puede desviarse de forma relevante, y ese margen debería contemplarse al fijar provisiones.

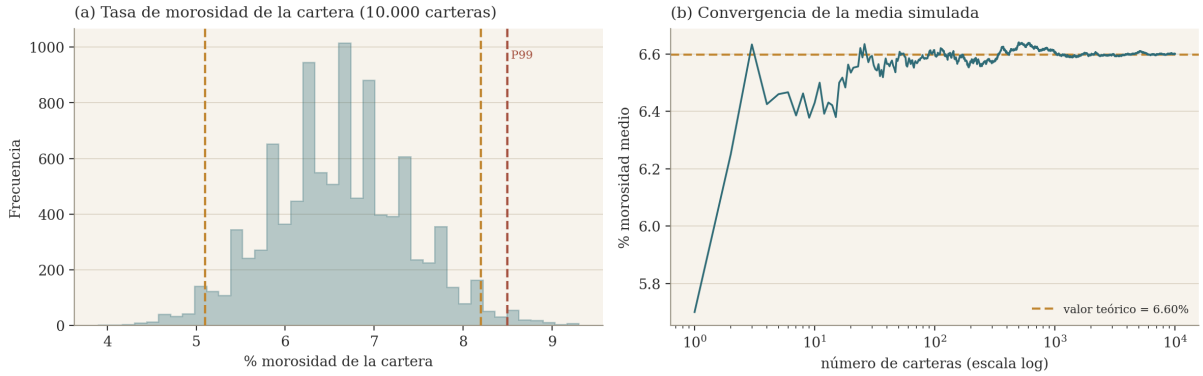


Figura 4: (a) Distribución de la tasa de morosidad de la cartera en 10.000 simulaciones, con el intervalo del 95 % y el percentil 99. (b) Convergencia de la media simulada al valor teórico.

4.1 Escenarios por tamaño de cartera

Repetimos la simulación para carteras de distinto tamaño (Tabla 2, Figura 5). La tasa media esperada se mantiene en 6,6 % en todos los casos, pero la dispersión cambia de forma marcada, con 100 créditos la morosidad puede ir de 2,0 % a 12,0 %, mientras que con 5.000 se concentra entre 5,9 % y 7,3 %. Es el efecto de diversificación. Para la decisión, una cartera pequeña exige un margen de provisión proporcionalmente mayor, porque su resultado es mucho menos predecible.

Tabla 2: Tasa de morosidad simulada según el tamaño de la cartera (10.000 simulaciones cada una).

Tamaño (N)	Media	IC 95 %	Ancho	Percentil 99
100	6,6 %	[2,0%; 12,0%]	10,0 pp	13,0 %
500	6,6 %	[4,6%; 8,8%]	4,2 pp	9,4 %
1.000	6,6 %	[5,1%; 8,2%]	3,1 pp	8,5 %
5.000	6,6 %	[5,9%; 7,3%]	1,4 pp	7,4 %

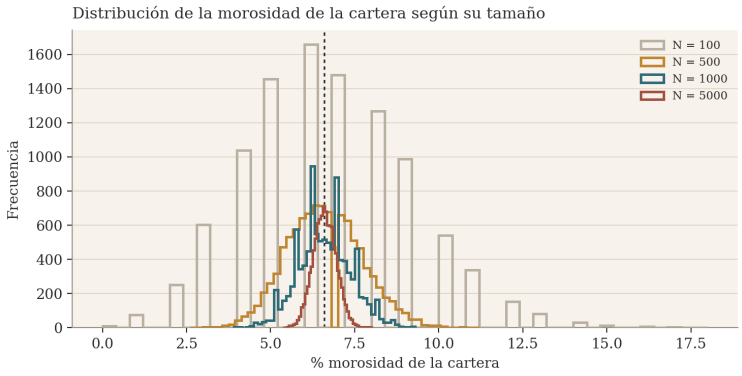


Figura 5: Distribución de la tasa de morosidad de la cartera según su tamaño. A mayor tamaño, menor dispersión en torno al mismo valor esperado.

5. Análisis de robustez

(15 pts) Evalúen la sensibilidad de los resultados de S1 frente a outliers y supuestos estadísticos (jackknife, bootstrap o simulaciones con distribuciones alternativas); distingan conclusiones confiables de aquellas que requieren cautela.

Para medir la sensibilidad de los resultados de S1 a los valores extremos comparamos la media del ingreso con estimadores robustos y aplicamos jackknife (Tabla 3). La media completa, 6.670, baja a 5.955 al recortar el 5 % de los casos y a 6.166 al quitar el 1 % superior, acercándose a la mediana de 5.400. El error estándar jackknife de la media es 41,5 y la observación más influyente es un ingreso de 3.008.750. La media del ingreso es entonces sensible a unos pocos registros y su lectura requiere cautela, conviene preferir la mediana.

Los valores extremos y los códigos especiales afectan también a las correlaciones, en dos sentidos opuestos. El caso más grave es la correlación entre las variables de atrasos, ya que pasa de 0,98, cuando se incluyen las 269 filas con los códigos 96 y 98, a 0,22 cuando se excluyen. La casi perfecta colinealidad que se reportó en S1 era, por tanto, un artefacto de esos códigos, no una propiedad real de los datos. En sentido contrario, la correlación de utilización con ratio de deuda parece nula (0,004) con todos los datos, pero sube a 0,120 (intervalo [0,115; 0,126]) al quitar los outliers evidentes, que la escondían. En cambio, la diferencia de edad entre morosos y no morosos se mantiene idéntica al eliminar los 609 duplicados (−6,82 años, $t \approx -50$), lo que confirma su robustez. En síntesis, la media del ingreso y las dos correlaciones sensibles a valores atípicos requieren cautela, la diferencia de edad, la tasa de morosidad y las correlaciones moderadas ya limpias son confiables.

Tabla 3: Sensibilidad de la media del ingreso a los valores extremos.

Estimador	**Valor**
Media completa	6.670,22
Media recortada al 5 %	5.954,51
Media sin el 1 % superior	6.166,21
Mediana	5.400,00

6. Preparación para la Sumativa 3

(9 pts) Documenten un reporte de resultados validados: parámetros robustos, correlaciones estables, observaciones influyentes identificadas y recomendaciones metodológicas para S3.

La Tabla 4 resume qué resultados de S1 quedaron validados y cuáles requieren cautela.

Tabla 4: Reporte de resultados validados para la Sumativa 3.

Resultado de S1	**Validación en S2**	**Estado**
Edad media y nº de líneas	Clásico, percentil y BCa coinciden	Robusto
Ingreso medio	BCa se corre por asimetría; sensible a outliers	Cautela
Diferencia de edad (Welch)	Permutación y quita de duplicados dan lo mismo	Robusto
Edad vs morosidad; líneas vs inmobiliarios	IC bootstrap estrechos, no cruzan 0	Robusto
Correlación entre atrasos	0,98 con códigos es artefacto; 0,22 sin ellos	Revisar códigos
Utilización vs ratio de deuda	Nula con outliers, 0,12 sin ellos	Revisar limpieza
Morosidad global (6,68 %)	Monte Carlo la reproduce (6,6 %)	Robusto

Recomendaciones metodológicas para S3: usar la mediana del ingreso en lugar de la media. Eliminar o acotar los valores extremos y los códigos 96 y 98 antes de modelar, porque distorsionan tanto medias como correlaciones. Tener presente que, una vez excluidos esos códigos, las variables de atrasos muestran correlación moderada (cerca de 0,22 a 0,31) y no la colinealidad casi perfecta que sugería el valor crudo, y tratar el desbalance de clases con técnicas de remuestreo. La observación de ingreso igual a 3.008.750 se marca como influyente y se revisará en la siguiente fase.

7. Bibliografía

Referencias en formato APA 7.ª edición, citadas explícitamente en el texto.

Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association*, 82(397), 171–185. `https://doi.org/10.1080/01621459.1987.10478410`

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap.* Chapman & Hall.

Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer.

Kaggle. (2011). *Give Me Some Credit* [Conjunto de datos]. Kaggle. `https://www.kaggle.com/c/GiveMeSomeCredit`

Robert, C. P., & Casella, G. (2004). *Monte Carlo statistical methods* (2.ª ed.). Springer.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. `https://doi.org/10.1038/s41592-019-0686-2`