MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Informe técnico grupal · 60 %

Ttulo del proyecto:	Análisis del Riesgo Crediticio
Integrantes:	«nombres completos (3-4 integrantes)»
Dataset:	Give Me Some Credit (Kaggle, 2011)
Docente:	«nombre del docente»
Fecha:	«dd/mm/aaaa»
Repositorio GitHub:	`https://github.com/usuario/repositorio`

Información de la evaluación

Fase: 4: Presentación y comunicación **Ponderación:** 60 % de la nota final
Entregables: Informe PDF (máx. 10 págs.) · Notebook maestro `.ipynb` · Presentación · Repositorio GitHub
Resultados de aprendizaje: RA1, RA2 y RA3 (esta evaluación los integra). **Prerrequisitos:** Sumativas 1 y 2.

Conexión con evaluaciones anteriores

Cada decisión de esta fase se fundamenta en S1 y S2: el manejo de faltantes y outliers, la selección de variables, la lectura de la colinealidad y la validación por bootstrap. La progresión S1 → S2 → S3 se hace explícita a lo largo del informe.

Índice

1 Manejo inteligente de datos faltantes **2**
1.1 Referencia al análisis de faltantes de S1 . . . 2
1.2 Imputación mediante regresión lineal múltiple . . . 2
1.3 Comparación de estrategias de imputación . . . 3

2 Clasificación mediante regresión logística **3**
2.1 Preparación de datos informada por S1 . . . 3
2.2 Selección de variables informada por S1 y S2 . . . 4
2.3 Evaluación de estabilidad mediante bootstrap . . . 5
2.4 Diagnóstico de supuestos . . . 6
2.5 Evaluación de desempeño predictivo . . . 7

3 Análisis comparativo del impacto de la imputación **7**

4 Síntesis integrada e informe final **8**

5 Presentación del proyecto **9**

6 Bibliografía **9**

1. Manejo inteligente de datos faltantes

1.1 Referencia al análisis de faltantes de S1

En S1 se identificaron faltantes en solo dos variables, el ingreso mensual, con 29.731 casos (19,8 %), y el número de dependientes, con 3.924 (2,6 %). Ninguna otra variable presenta vacíos. Diagnosticar el mecanismo de esos faltantes importa porque condiciona la validez de cualquier imputación. De los tres mecanismos clásicos, el faltante completamente al azar (MCAR) implicaría que la ausencia no depende de nada, lo que rara vez se cumple; el faltante no al azar (MNAR) implicaría que la ausencia depende del propio valor no observado (por ejemplo, que los solicitantes de ingreso muy alto o muy bajo tiendan a no declararlo), y sería el caso más difícil, porque no se corrige con las variables disponibles. Adoptamos el supuesto intermedio, el faltante al azar condicional (MAR), es decir, la ausencia del ingreso se explica por características observadas del solicitante, de modo que una imputación basada en esas características es defendible (Little & Rubin, 2019). Es un supuesto, no una certeza, y lo declaramos como tal. Se arrastran además de S1 la eliminación del registro con edad 0, el acotamiento de los códigos 96 y 98 en las variables de atrasos a su máximo legítimo, y el recorte al percentil 99 de las colas de utilización, ratio de deuda e ingreso.

1.2 Imputación mediante regresión lineal múltiple

Los predictores de cada regresión se eligieron con la matriz de correlaciones de S1, priorizando las relaciones que S2 validó como estables (Tabla 1). Ninguna correlación con el ingreso supera 0,13 en valor absoluto, lo que anticipa un ajuste débil. Para los dependientes, en cambio, la edad aporta una relación más clara ($r = -0{,}21$), coherente con lo observado en S1.

Tabla 1: Correlaciones de S1 usadas para seleccionar los predictores de imputación.

Variable a imputar	**Predictor (de S1)**	r
Ingreso mensual	Préstamos inmobiliarios	+0,13
	Líneas y préstamos abiertos	+0,09
	Edad	+0,04
	Ratio de deuda	−0,04
Nº de dependientes	Edad	−0,21
	Préstamos inmobiliarios	+0,12
	Líneas y préstamos abiertos	+0,04

Ajustamos cada modelo sobre las observaciones completas. El ajuste del ingreso es débil por construcción ($R^2 = 0{,}02$), confirmación directa de lo que se encontró en S1, de que el ingreso correlaciona poco con el resto. El de dependientes es mayor ($R^2 = 0{,}07$). Se imputaron 29.731 valores de ingreso y 3.924 de dependientes, acotando las predicciones a valores no negativos y redondeando las de dependientes a enteros.

Verificación de supuestos. Los residuos de la regresión del ingreso tienen media cero y no correlacionan con el valor ajustado (Figura 1b), de modo que la linealidad en media es razonable. Sin embargo, son fuertemente asimétricos, así que el supuesto de normalidad no se cumple, algo esperable dada la cola larga del ingreso ya descrita en S1. Para el propósito de imputar (predicción puntual) la falta de normalidad no invalida el método, pero conviene tenerla presente.

Encogimiento de varianza. La limitación más relevante de la imputación por regresión es que reemplaza cada faltante por su predicción, que carece del término de error. En consecuencia, los valores imputados tienen mucha menos dispersión que los observados, es decir, la desviación estándar cae de 14.385 a 2.039, un 86 % menos, visible en el pico estrecho de la Figura 1a. Esto subestima la variabilidad real del ingreso y podría atenuar su relación con otras variables. Se asume como costo conocido del método, una *imputación múltiple*, que añade ruido aleatorio y

promedia varias imputaciones, restauraría esa variabilidad y sería la opción preferible si el ingreso fuese un predictor central, cosa que, como veremos, no ocurre.

1.3 Comparación de estrategias de imputación

Se compararon tres estrategias (Tabla 2). La eliminación de casos incompletos pierde cerca de 30.000 registros, lo que reduce la potencia y puede sesgar si el faltante no es MCAR. La imputación simple por la mediana y la imputación por regresión conservan el tamaño completo. Las tres preservan la mediana en torno a 5.400 y una correlación con la morosidad igualmente débil (alrededor de −0,05), lo que indica que la relación del ingreso con el objetivo no se distorsiona con ninguna. Se adopta la **imputación por regresión** para el resto del desarrollo, conserva todos los casos, usa la estructura de correlaciones de S1 y no altera la relación con la variable objetivo, asumiendo el encogimiento como limitación.

Tabla 2: Comparación de estrategias de imputación (variable ingreso mensual).

Estrategia	n	**Media**	**Mediana**	**Desv.**	**corr(ing., mora)**
Eliminación	120.268	6.349	5.400	4.358	−0,056
Imputación simple	149.999	6.142	5.400	3.836	−0,050
Imputación regresión	149.999	5.635	4.800	4.162	−0,045

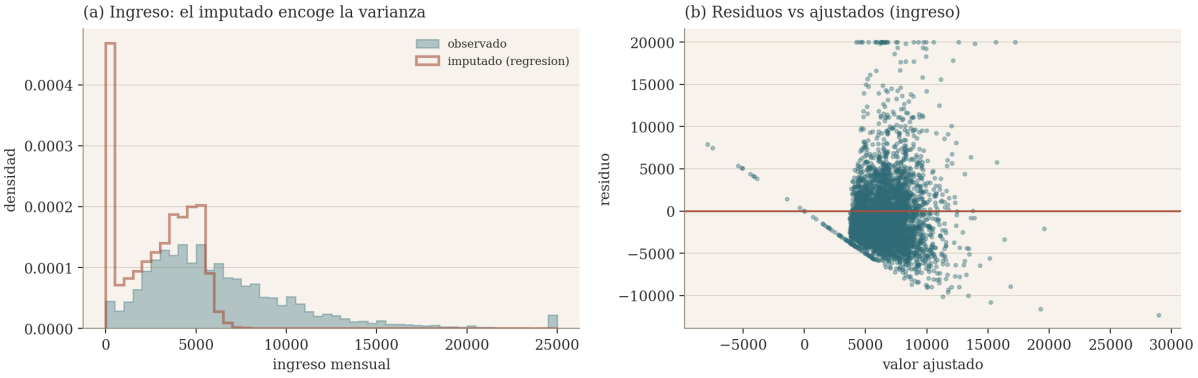


Figura 1: (a) Distribución del ingreso observado frente a los valores imputados por regresión, se aprecia el encogimiento de varianza. (b) Residuos frente a valores ajustados, media cero y sin patrón, aunque asimétricos.

2. Clasificación mediante regresión logística

2.1 Preparación de datos informada por S1

Sobre el conjunto imputado se hizo una partición 70/30 estratificada por la variable objetivo, dado el desbalance de S1 (6,7 % de morosos), donde 104.999 casos de entrenamiento y 45.000 de prueba, ambos con la misma tasa de morosidad. Los predictores se estandarizaron, de modo que los coeficientes y odds ratios se interpretan por desviación estándar y son comparables entre sí. Los outliers de utilización, ratio de deuda e ingreso ya se recortaron al percentil 99 como en S1, y los códigos 96/98 de atrasos se acotaron a su máximo legítimo: así se limita su influencia sin descartar los 269 casos afectados. Para el punto de operación de la clasificación se usó ponderación por clase, que compensa el desbalance dando más peso a la clase minoritaria.

2.2 Selección de variables informada por S1 y S2

Se construyeron tres modelos con criterios distintos. El **Modelo 1** usa solo las señales que S1 destacó y S2 validó como estables (Tabla 3); el **Modelo 2** aplica selección hacia adelante por AIC/BIC; y el **Modelo 3** parte del modelo completo y elimina hacia atrás los tres predictores que S1 y S2 caracterizaron como más débiles (ingreso, ratio de deuda y dependientes), combinando la eliminación hacia atrás con el conocimiento del dominio, ambos del apunte del curso (Maidana, 2026).

Tabla 3: Modelo 1: variables y hallazgo de S1/S2 que respalda cada una.

Variable	**Fundamento en S1/S2**
Atrasos 30–59	Señal más fuerte en S1 (riesgo relativo 5,1; χ^2 significativo), validada en S2.
Edad	Diferencia significativa entre morosos y no morosos (Welch en S1, confirmada por permutación en S2).
Utilización	Alta relación con el impago; mayor factor de riesgo del modelo.
Ingreso	Relación monótona por cuartil en S1, pese a su correlación lineal débil.
Ratio de deuda	Indicador de carga financiera del solicitante.
Dependientes	Carga familiar; correlacionada con la edad ($-0{,}21$ en S1).

Para justificar por qué AIC y BIC retienen las diez variables reportamos la trayectoria de la selección hacia adelante (Tabla 4). Ambos criterios descienden de forma monótona al agregar cada variable; incluso el último paso, agregar dependientes, reduce el BIC (de 41.653,7 a 41.635,9), porque la mejora de $-2\log L$ supera la penalización de BIC, $\ln(n) \approx 11{,}6$. Por eso ninguno de los dos descarta variables, a este tamaño muestral toda variable es estadísticamente significativa. El modelo reducido (M3), en cambio, descarta esas tres variables débiles y aun así conserva casi todo el desempeño (Tabla eftab:perf). Para validar la comparación con robustez se usó validación cruzada de cinco particiones, la práctica que el apunte del curso recomienda como estándar, el AUC de validación cruzada casi coincide con el de prueba en los tres modelos, lo que descarta sobreajuste, y confirma que el modelo completo (0,853) y el reducido (0,852) son prácticamente equivalentes, muy por encima del de dominio (0,824). El modelo final, con el mejor AUC, es el completo, aunque bajo el principio de parsimonia del apunte el reducido de siete variables sería igualmente defendible y constituye el núcleo robusto.

Tabla 4: Trayectoria de la selección hacia adelante: AIC y BIC al incorporar cada variable.

Paso	**Variable incorporada**	**AIC**	**BIC**
1	Utilización	44.292,5	44.311,7
2	Atrasos 30–59	42.549,4	42.578,1
3	Atrasos 90+	42.117,8	42.156,0
4	Edad	41.929,7	41.977,5
5	Líneas y préstamos	41.779,4	41.836,7
6	Atrasos 60–89	41.712,7	41.779,6
7	Ingreso	41.671,4	41.747,9
8	Ratio de deuda	41.618,9	41.704,9
9	Préstamos inmobiliarios	41.558,1	41.653,7
10	Nº de dependientes	41.530,7	41.635,9

Tabla 5: Desempeño de los tres modelos: AUC en prueba, AUC por validación cruzada (5 particiones) y métricas de clasificación (umbral 0,5).

Modelo	Vars.	AUC test	CV-AUC	Acc.	Prec.	Recall	F1
M1 (dominio, S1/S2)	6	0,828	$0{,}824 \pm 0{,}006$	0,769	0,187	0,733	0,298
M2 (stepwise AIC/BIC)	10	**0,855**	$0{,}853 \pm 0{,}004$	0,800	0,215	0,751	0,334
M3 (reducido informado)	7	0,854	$0{,}852 \pm 0{,}004$	0,799	0,213	0,747	0,332

2.3 Evaluación de estabilidad mediante bootstrap

Siguiendo el enfoque de S2, se aplicó bootstrap al modelo final (500 remuestras del conjunto de entrenamiento con reajuste del modelo en cada una), construyendo intervalos percentil al 95 % **tanto para los coeficientes como para los odds ratios** (Tabla 6, Figura 2) y comparándolos con los intervalos de Wald. El número de remuestras es menor que en S2 (10.000) por costo computacional, allí cada remuestra recalculaba una media o correlación, una operación directa. Aquí cada remuestra reajusta un modelo de regresión logística completo por máxima verosimilitud sobre más de 100.000 observaciones, un proceso iterativo mucho más costoso. Con 500 remuestras el intervalo percentil al 95 % ya es estable para este tamaño muestral (Efron & Tibshirani, 1993). Conviene una aclaración metodológica que evita confusiones, los intervalos de inferencia (Wald y bootstrap) provienen del ajuste sin ponderación de clase, que es el estimador de máxima verosimilitud y el que produce coeficientes interpretables. La ponderación por clase se reserva para el punto de operación de la clasificación (matrices de confusión), no para la inferencia. Así la comparación Wald-bootstrap es homogénea. Todos los parámetros resultan estables, es decir, ningún intervalo cruza el 1 en odds ratios (equivalente a cruzar el 0 en coeficientes), y los intervalos bootstrap son casi idénticos a los de Wald. Esa coincidencia no es casual, con más de 100.000 observaciones la normalidad asintótica del estimador de máxima verosimilitud ya se sostiene, de modo que ambos enfoques convergen; el bootstrap, que no supone normalidad, lo confirma empíricamente.

Tabla 6: Modelo final: coeficiente y odds ratio con IC bootstrap al 95 % (por desviación estándar). Los IC de Wald coinciden en la práctica.

Variable	coef. (IC bootstrap)	OR (IC bootstrap)	Estable
Utilización	+0,82 [+0,78; +0,85]	2,26 [2,19; 2,35]	sí
Atrasos 30–59	+0,29 [+0,27; +0,32]	1,34 [1,31; 1,38]	sí
Atrasos 90+	+0,27 [+0,21; +0,33]	1,31 [1,23; 1,40]	sí
Líneas y préstamos	+0,17 [+0,15; +0,21]	1,19 [1,16; 1,23]	sí
Atrasos 60–89	+0,12 [+0,06; +0,17]	1,13 [1,06; 1,19]	sí
Préstamos inmobiliarios	+0,11 [+0,08; +0,14]	1,12 [1,08; 1,15]	sí
Nº de dependientes	+0,07 [+0,04; +0,09]	1,07 [1,05; 1,10]	sí
Ingreso	−0,21 [−0,24; −0,17]	0,81 [0,78; 0,84]	sí
Edad	−0,21 [−0,24; −0,17]	0,81 [0,79; 0,84]	sí
Ratio de deuda	−0,14 [−0,17; −0,11]	0,87 [0,84; 0,89]	sí

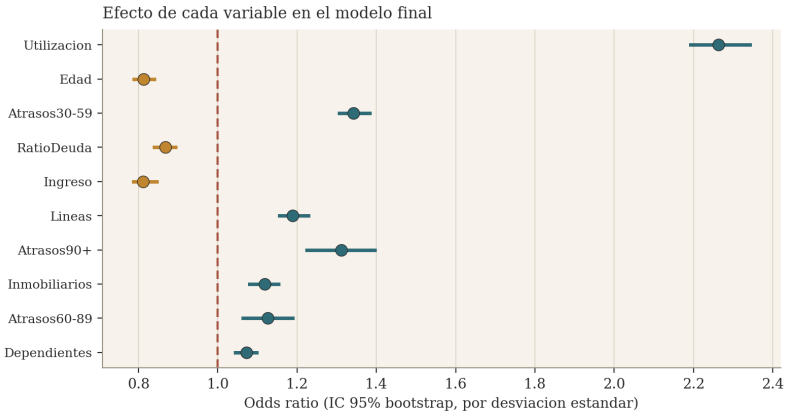


Figura 2: Odds ratios del modelo final con IC bootstrap al 95 %. La línea marca OR = 1; a la derecha, factores de riesgo; a la izquierda, protectores.

La lectura de negocio es directa y coherente con S1. La utilización de crédito es el mayor factor de riesgo, donde cada desviación estándar adicional más que duplica las probabilidades de morosidad (OR = 2,26), razonable porque un cliente que agota su crédito disponible está bajo mayor presión financiera. El historial de atrasos sigue en importancia, con las tres ventanas (30-59, 60-89 y 90+ días) aportando de forma independiente. En sentido protector, la edad y el ingreso reducen el riesgo (OR = 0,81 cada uno), consistente con que clientes mayores y de mayor ingreso incumplen menos.

2.4 Diagnóstico de supuestos

Se revisaron tres aspectos. Primero, la **multicolinealidad**, los factores de inflación de varianza (VIF) son todos menores a 2,7, con los mayores en las variables de atrasos (2,69 en 60-89 y 2,55 en 90+) y el resto bajo 1,5 (Figura 3). Esto confirma directamente lo que se encontró en S2, es decir, la colinealidad casi perfecta que sugería la correlación cruda de 0,98 entre atrasos era un artefacto de los códigos 96/98. Una vez acotados, no hay multicolinealidad problemática y las tres variables conviven en el modelo. Segundo, las **observaciones influyentes**, los residuos de Pearson extremos ($|r| > 3$) son escasos (2,3 % de las observaciones), sin registros que dominen el ajuste. Tercero, la **linealidad en el logit**, donde el modelo supone que cada predictor se relaciona linealmente con el logaritmo de las probabilidades. Para las variables de conteo (atrasos, líneas, dependientes) es una simplificación razonable dado su rango acotado tras el tratamiento de S1, y S1 ya había advertido que el ingreso guarda una relación no lineal (por cuartil) con el objetivo, que un modelo logístico lineal capta solo parcialmente. Lo dejamos señalado como la limitación estructural del modelo y como motivación para explorar alternativas no lineales.

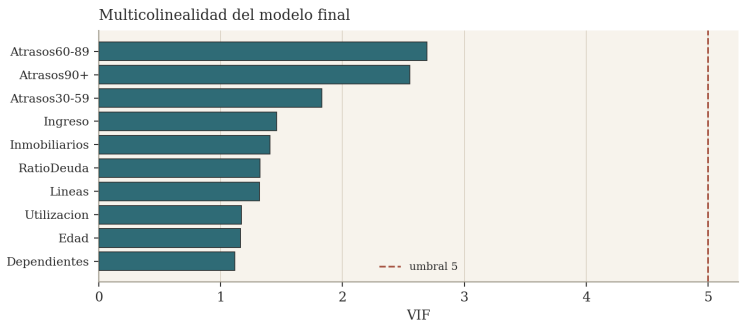


Figura 3: Factores de inflación de varianza del modelo final; todos quedan holgadamente bajo el umbral de 5.

2.5 Evaluación de desempeño predictivo

El modelo final alcanza un AUC de 0,855 en prueba y 0,854 en entrenamiento, prácticamente iguales, lo que descarta el sobreajuste. Las matrices de confusión y las métricas derivadas para ambos conjuntos (Tabla 7, Figura 4) son consistentes entre sí. Con umbral 0,5 y ponderación por clase, el modelo recupera el 75 % de los morosos (sensibilidad alta) a costa de una precisión baja (0,21), lo esperable con una tasa base de 6,7 %, de cada cinco clientes marcados como riesgosos, cerca de uno lo es realmente, pero se captura a tres de cada cuatro morosos verdaderos. Este balance prioriza no dejar pasar morosos, criterio adecuado en riesgo crediticio, donde el costo de un falso negativo (aprobar a quien luego incumple) suele superar al de un falso positivo (rechazar a un buen cliente). El AUC, insensible al umbral, resume mejor la capacidad discriminante que la accuracy, que aquí resulta engañosa: un clasificador que predijera "no moroso" para todos alcanzaría un 93 % de accuracy sin detectar un solo moroso.

Tabla 7: Matrices de confusión y métricas del modelo final en entrenamiento y prueba (umbral 0,5).

	Entrenamiento		**Prueba**	
	Pred. No	**Pred. Sí**	**Pred. No**	**Pred. Sí**
Real no moroso	78.185	19.796	33.738	8.254
Real moroso	1.794	5.224	748	2.260
Accuracy 0,79 / 0,80	*Precisión* 0,21 / 0,22		*Recall* 0,74 / 0,75	
Especificidad 0,80 / 0,80	*AUC* 0,854 / 0,855		(valores entrenamiento / prueba)	

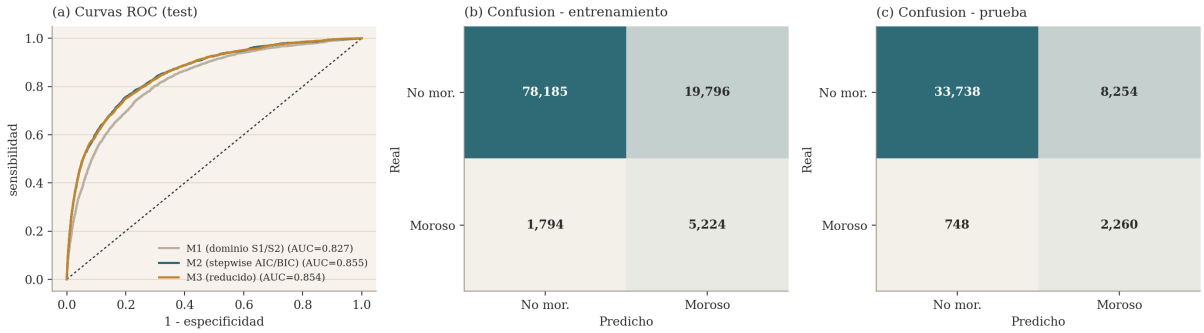


Figura 4: (a) Curvas ROC de los tres modelos en prueba. (b) Matriz de confusión en entrenamiento. (c) Matriz de confusión en prueba.

3. Análisis comparativo del impacto de la imputación

Para cerrar el análisis de la Parte 1 se ajustó el modelo final con los tres conjuntos (eliminación, imputación simple e imputación por regresión) y se compararon el tamaño, el AUC y el **vector de coeficientes con sus intervalos de confianza** (Tabla 8), no solo el del ingreso. El AUC casi no cambia (0,842 a 0,855). Los coeficientes de la utilización y de los atrasos son estables entre las tres estrategias, sus intervalos de confianza se solapan ampliamente, lo que muestra que la señal fuerte del modelo no depende de cómo se traten los faltantes. El único coeficiente que se desplaza de forma apreciable es el del ingreso, que pasa de $-0{,}18$ con imputación a $-0{,}23$ con eliminación. La explicación es de composición muestral, donde, al descartar 30.000 casos incompletos, la eliminación cambia el perfil de la muestra y mueve el coeficiente del predictor más débil y sensible, aunque sin alterar las conclusiones sustantivas. Es exactamente el riesgo que la eliminación introduce y que la imputación evita, y refuerza la elección de la imputación

por regresión como estrategia por defecto.

Tabla 8: Impacto de la estrategia de imputación: coeficientes estandarizados con IC de Wald al 95 %.

Estrategia	n / **AUC**	**coef. Utilización**	**coef. Atrasos 30–59**	**coef. Ingreso**
Eliminación	36.081 / 0,842	+0,76 [+0,73; +0,79]	+0,32 [+0,29; +0,34]	−0,23 [−0,26; −0,19]
Imputación simple	45.000 / 0,855	+0,82 [+0,79; +0,85]	+0,29 [+0,27; +0,32]	−0,18 [−0,21; −0,15]
Imputación regresión	45.000 / 0,855	+0,82 [+0,79; +0,84]	+0,29 [+0,27; +0,32]	−0,21 [−0,24; −0,17]

4. Síntesis integrada e informe final

Resumen ejecutivo. El proyecto construyó, sobre el conjunto *Give Me Some Credit*, un modelo de clasificación de riesgo crediticio con un AUC de 0,855, estable y libre de multicolinealidad. El riesgo de morosidad se explica sobre todo por la utilización de crédito y el historial de atrasos, y disminuye con la edad y el ingreso. El modelo distingue tres de cada cuatro morosos y está listo para apoyar decisiones de aprobación una vez calibrado su umbral según la política de riesgo de la entidad.

Introducción. El problema es de decisión bajo incertidumbre, hay que estimar, antes de otorgar un crédito, la probabilidad de que un solicitante caiga en morosidad grave (atraso de 90 o más días en dos años). El conjunto reúne 150.000 solicitantes y diez predictores, con una tasa de morosidad del 6,7 %. La dificultad central es doble, el fuerte desbalance de clases y la presencia de faltantes, outliers y códigos especiales, todos caracterizados en las fases previas.

Metodología integrada. La metodología encadena las tres sumativas de forma acumulativa. *S1* caracterizó el problema mediante estadística descriptiva e inferencia, donde se cuantificó el desbalance, los faltantes del ingreso, los outliers y los códigos 96/98, y detectó las señales candidatas (el historial de atrasos como la más fuerte, la edad y el ingreso por cuartil). *S2* validó esos hallazgos con remuestreo y simulación (bootstrap, permutación y Monte Carlo) y corrigió uno central, es decir, la correlación de 0,98 entre las variables de atrasos era un artefacto de los códigos, no colinealidad real. *S3* llevó todo eso al modelamiento, imputó el ingreso por regresión sabiendo de antemano que sería un predictor débil, seleccionó variables con tres criterios apoyados en las señales validadas, comprobó con los VIF que ya no existe colinealidad severa, y validó la estabilidad de los odds ratios con bootstrap, exactamente la técnica introducida en S2.

Resultados y discusión crítica. El modelo final discrimina bien y todos sus parámetros son estables, pero un informe profesional debe declarar las limitaciones de todo estudio. Primero, la imputación por regresión encoge la varianza del ingreso un 86 %, lo que subestima su variabilidad. Una imputación múltiple sería preferible si el ingreso fuese central, aunque el análisis de la Parte 3 muestra que no lo es. Segundo, el coeficiente del ingreso se mueve un 25 % entre estrategias de imputación, señal de que su estimación es frágil precisamente por ser un predictor débil. Tercero, a este tamaño muestral AIC y BIC retienen todas las variables, y la validación cruzada no distingue el modelo completo del reducido, de modo que la selección automática aporta poco frente al juicio informado por S1/S2, y la parsimonia debe buscarse por criterios de negocio, no solo estadísticos. Cuarto, el modelo es lineal en el logit y S1 ya mostró relaciones no lineales que no capta del todo.

Conclusiones y recomendaciones. El modelo es apto para apoyar decisiones de aprobación siempre que el umbral se calibre según el costo relativo de falsos negativos y positivos, que en crédito rara vez es simétrico. Se recomienda operar por probabilidad de riesgo antes que por la clasificación binaria a 0,5, priorizar la utilización y el historial de atrasos en las políticas de crédito, monitorear periódicamente la estabilidad de los coeficientes ante nuevos datos, y documentar el tratamiento de los códigos especiales para evitar que reaparezca el artefacto detectado en S2. Como trabajo futuro, modelos no lineales (árboles de decisión, *gradient boosting*) podrían

mejorar la discriminación aprovechando las relaciones no lineales que S1 insinuó, en particular la del ingreso por cuartil.

5. Presentación del proyecto

(6 pts) La presentación es un video de 10 minutos que debe grabar el grupo. Se propone el siguiente guion.

El video sigue la progresión del proyecto en cinco bloques de unos dos minutos, uno por integrante para asegurar una participación equitativa. El primer bloque plantea el problema de negocio y describe los datos (S1), predecir morosidad grave en un conjunto desbalanceado de 150.000 solicitantes, y por qué importa a una entidad crediticia. El segundo resume los hallazgos exploratorios e inferenciales de S1, es decir, el desbalance, los faltantes, los outliers y las señales de riesgo (atrasos, edad, ingreso por cuartil). El tercero presenta la validación de S2 (bootstrap, permutación y Monte Carlo) y destaca lo que se encontró sobre el artefacto de la correlación de atrasos, que corrigió la lectura de colinealidad. El cuarto expone el modelamiento de S3, la imputación y su comparación, los tres modelos, el bootstrap de los coeficientes, los diagnósticos y el desempeño. Alguno de los cuatro cierra con las conclusiones y recomendaciones, enfatizando cómo cada fase informó a la siguiente y qué decisiones de negocio habilita el modelo. Se cuida la precisión técnica, el uso de lenguaje claro y la gestión del tiempo.

6. Bibliografía

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning*. Springer.

Kaggle. (2011). *Give Me Some Credit* [Conjunto de datos]. `https://www.kaggle.com/c/GiveMeSomeCredit`

Little, R. J. A., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley.

Maidana, J. P. (2026). *Selección de variables y comparación de modelos* [Apunte del curso MCDI501]. Universidad Andrés Bello.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. *Proc. 9th Python in Science Conf.*, 92–96.

Recordatorio

Todas las decisiones metodológicas se fundamentan en los resultados de S1 y S2, y la progresión S1 → S2 → S3 se evidencia de forma explícita a lo largo del informe.